

جامعة ابن زهر
+0800441 800 8000
UNIVERSITÉ IBN ZOHR



الكلية متعددة التخصصات - ورازات
+044001 +08008000 - 00000000
FACULTÉ POLYDISCIPLINAIRE DE OUARZAZATE



Détection d'Intrusion Réseau par Apprentissage Automatique

Une Approche Hiérarchique Basée
sur les Données

Université Ibn Zohr

Faculté Polydisciplinaire de Ouarzazate

Master Mathématiques Appliquées pour la Science des Données

Etudiant : Abdelfattah BOUHLALI

Encadré par : Prof. Abdelkrim EL MOUATASIM

Prof. Examineur : Rabia Riad

Président : Jaouad Oudaani

Date : 04/07/2025

INTRODUCTION 01

04 Prétraitement

NSL-KDD 02

05 Modèles ML

Méthodologie 03

06 Autoencodeur

**Business
Overview**

07

10

**Résultats
multi-classes**

SVM-SMOTE

08

11

Discussion

**Résultats
binaire**

09

12


Conclusion

01

INTRODUCTION



Contexte et enjeux de la cybersécurité




Défis actuels

- Augmentation exponentielle des cyberattaques
- Sophistication croissante des techniques d'intrusion
- Interconnexion des systèmes critiques
- Limites des approches traditionnelles




Défis actuels

- Coûts annuels : milliards d'euros
- Incidents triplés en 10 ans
- Vulnérabilités zero-day en hausse



Limitations des systèmes IDS classiques




Approches traditionnelles

Détection par signatures

- + Efficace pour attaques connues
- - Incapable de détecter zero-day


Limitations critiques

- Maintenance coûteuse
- Taux élevé de faux positifs
- Adaptation lente aux nouvelles menaces



Objectifs du mémoire et contributions

Objectifs principaux



Innovation proposée

Approche hiérarchique combinant :

- Autoencodeur (détection d'anomalies)
- SVM-SMOTE (équilibre avancé)
- Classification progressive

Contributions attendues

Limitations critiques

- Maintenance coûteuse
- Taux élevé de faux positifs
- Adaptation lente aux nouvelles menaces

02 NSL-KDD



Présentation générale du dataset NSL-KDD

Caractéristiques générales


- 125,973 échantillons d'entraînement
- 22,544 échantillons de test
- 41 attributs par connexion
- 5 classes : Normal + 4 types d'attaques
- Amélioration de KDD Cup 99

Avantages de NSL-KDD

- Élimination des doublons
- Distribution plus équilibrée
- Référence standard en recherche

Défi majeur

- Déséquilibre critique : ratio 1295 :1 entre Normal et U2R 2/4



Description des 41 caractéristiques

Caractéristiques générales

Caractéristiques de base (9)	Caractéristiques de trafic (13)	Caractéristiques de contenu (19)
duration	count	hot
protocol_type	srv_count	num_failed_logins
service	serror_rate	num_compromised
flag	srv_serror_rate	root_shell
+ 5 autres	+ 9 attributs hôtes	+ 15 autres



Taxonomie des attaques


Catégorie	Description	Exemples	Proportion
DoS	Attaques par déni de service visant à saturer les ressources	neptune, smurf, pod	36.5%
Probe	Tentatives de reconnaissance pour découvrir les vulnérabilités	satan, portsweep, nmap	9.3%
R2L	Intrusions distantes cherchant un accès local non autorisé	warezclient, imap, spy	0.8%
U2R	Élévations de privilèges d'utilisateur vers administrateur	buffer_overflow, rootkit	0.04%

03


Méthodologie



Schéma global du système hiérarchique



Étapes du pipeline de traitement



Prétraitement des données

- Encodage par fréquence des variables catégorielles
- Standardisation Z-score des variables numériques



Classification binaire (Étape 1)

- Évaluation de 7 algorithmes d'apprentissage automatique
- Sélection du modèle le plus performant
- Détection : Normal vs Attaque



Classification multi-classes (Étape 2)

- Application uniquement sur les échantillons "Attaque"
- Utilisation de SVM-SMOTE pour équilibrer les classes
- Classification fine : DoS, Probe, R2L, U2R

Avantages de l'approche hiérarchique

- Spécialisation progressive
- Maintenance facilitée
- Performance optimisée

04

Prétraitement



Encodage des variables catégorielles

Variables catégorielles identifiées

- protocol_type : TCP, UDP, ICMP
- service : HTTP, FTP, SMTP, etc. (70 services différents)
- flag : SF, SO, REJ, etc. (11 états de connexion)

Méthode : Encodage par fréquence

- Pour une variable catégorielle X avec catégories $\{c_1, c_2, \dots, c_k\}$:
 $\text{encoded}(c_i) = \text{rank}(\text{freq}(c_i))$

où $\text{freq}(c_i)$ est la fréquence d'apparition de c_i

Exemple - protocol_type

Protocole	protocol	type
TCP	190,065	3
UDP	20,354	2
ICMP	1,288	1

Normalisation des données

Standardisation Z-score

- Pour chaque caractéristique numérique x_i :

$$Z_i = \frac{x_i - \mu}{\sigma}$$

où μ est la moyenne et σ l'écart-type de la caractéristique

Nécessité de la normalisation


- Échelles très différentes des attributs
- duration : 0–58,329 secondes
- src_bytes : 0–1,379,963,888 octets
- count : 0–511 connexions

Bénéfices obtenus

- Convergence plus rapide des algorithmes
- Performances améliorées pour SVM et MLP
- Évite la domination d'attributs à grande échelle


05

Modèles ML




Vue d'ensemble des modèles testés

Algorithmes d'apprentissage supervisé évalués



Approche non-supervisée



Arbres de décision et Random Forest



Arbres de décision


Critère d'entropie :

$$H(S) = - \sum_{i=1}^c p_i \log_2(p_i)$$

Gain d'information :

$$\text{Gain}(S, A) = H(S) - \sum_{j=1}^v \frac{|S_j|}{|S|} H(S_j)$$

- Sélection du meilleur attribut de division
- Arrêt par critères de profondeur/pureté
- + Interprétabilité élevée
- - Tendance au surapprentissage



Random Forest


Bagging + Sélection aléatoire :

1. Échantillonnage bootstrap (taille n)
2. Sélection de $\sqrt{p}$ attributs par nœud
3. Construction de T arbres
4. Vote majoritaire final

$$\hat{y} = \text{mode}\{h_1(x), h_2(x), \dots, h_T(x)\}$$

- + Réduction du surapprentissage
- + Robustesse aux outliers
- - Perte d'interprétabilité

Support Vector Machine (SVM)



Formulation mathématique

Problème d'optimisation :


$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

Contraintes :

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0, \quad i = 1, \dots, n$$

où C contrôle le compromis entre marge et erreurs.



Noyau RBF (Gaussien)


$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

- γ contrôle la "portée" de chaque exemple
- Permet de capturer les relations non-linéaires
- Transformation implicite vers un espace de dimension supérieure

Avantages :

- + Très bonne généralisation
- + Efficace en haute dimension
- - Sensible aux hyperparamètres

Multi-Layer Perceptron (MLP)



Architecture utilisée


- **Couche d'entrée** : 41 neurones
- **Couche cachée** : 100 neurones (ReLU)
- **Couche de sortie** : 2 neurones (Softmax)

Fonction ReLU :

$$\text{ReLU}(x) = \max(0, x)$$

Fonction Softmax :

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$



Entraînement

Fonction de coût (entropie croisée) :

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \sum_{k=1}^K y_k^{(i)} \log(\hat{y}_k^{(i)})$$

Rétropropagation :

- Gradients par couche
- Descente de gradient
- Optimiseur : Adam
- + Non-linéarités complexes
- + Apprentissage automatique
- - Sensible aux hyperparamètres

AdaBoost - Algorithme de boosting

Principe d'AdaBoost

Objectif : Combiner séquentiellement des classificateurs faibles en se concentrant sur les exemples difficiles.

Algorithme

1. Initialiser : $w_1^{(i)} = \frac{1}{m}$ pour $i = 1, \dots, m$

2. Pour $t = 1$ à T :

- Entraîner h_t sur la distribution w_t

- Calculer l'erreur :

$$\epsilon_t = \sum_{i=1}^m w_t^{(i)} 1(y_i \neq h_t(x_i))$$

- Calculer le coefficient :

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1-\epsilon_t}{\epsilon_t} \right)$$

- Mettre à jour :

$$w_{t+1}^{(i)} = \frac{w_t^{(i)} \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$$

3. Classificateur final :

$$H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right)$$

Caractéristiques


- Classificateurs faibles : arbres de décision simples
- Adaptation des poids selon les erreurs
- Concentration sur les exemples mal classifiés
- Réduction progressive du biais

Avantages :


- + Amélioration itérative
- + Moins sensible au surapprentissage
- - Sensible aux outliers

06

Autoencodeur



Architecture de l'autoencodeur



Fonction de coût MSE et seuil de détection

Fonction de coût

Mean Squared Error (MSE) :

$$\mathcal{L}_{\text{MSE}} = \frac{1}{n} \sum_{i=1}^n \|x_i - \hat{x}_i\|^2$$

Fonction SELU :

$$\text{SELU}(x) = \lambda \begin{cases} x & \text{si } x > 0 \\ \alpha(e^x - 1) & \text{si } x \leq 0 \end{cases}$$

avec $\alpha = 1.673$ et $\lambda = 1.051$

- Auto-normalisation
- Stabilité d'entraînement
- Évite la saturation

Détection d'anomalies

Erreur de reconstruction :

$$\text{erreur}(x) = \|x - \hat{x}\|^2$$

Seuil de décision :

$$\tau = \text{percentile}_{95}(\{\text{erreur}(x_i) : y_i = \text{normal}\})$$

Classification :

$$\text{classe}(x) = \begin{cases} \text{Normal} & \text{si } \text{erreur}(x) \leq \tau \\ \text{Anomalie} & \text{si } \text{erreur}(x) > \tau \end{cases}$$

Résultat

$$\tau = 0.1696 \text{ sur NSL-KDD}$$

Visualisation des erreurs de reconstruction


Convergence de l'entraînement

- 37 époques jusqu'à convergence
- Perte finale d'entraînement : **0.106**
- Perte finale de validation : **0.054**
- Pas de surapprentissage observé

Hyperparamètres optimaux

- Taille du batch : 256
- Taux d'apprentissage : 0.001
- Optimiseur : Adam
- Patience early stopping : 10


Distribution des erreurs



- **Normal** : $\mu = 0.061$
- **Attaques** : $\mu = 0.421$
- Séparation claire des distributions

07

Stratégie hiérarchique



Étape 1 : Détection binaire (Normal vs Attaque)

Objectif de la première étape

Distinguer efficacement le **trafic normal** des **activités malveillantes**, quelle que soit leur nature.

Avantages de cette approche

- **Spécialisation** du modèle sur la détection globale
- **Sensibilité maximale** aux intrusions
- **Réduction** de la complexité du problème
- **Filtrage efficace** du trafic légitime

Performance attendue

- **Accuracy** > 80%
- **Rappel élevé** pour les attaques
- **Précision équilibrée**
- **Temps de traitement** acceptable

Modèles évalués

- 7 algorithmes supervisés
- 1 approche non-supervisée (autoencodeur)
- Validation croisée 5-fold
- Optimisation des hyperparamètres

Défi principal

Maintenir un **équilibre optimal** entre :

- Détection des vraies intrusions
- Minimisation des faux positifs
- Capacité de généralisation

Étape 2 : Classification des types d'attaques

Objectif de la seconde étape

Classifier les échantillons identifiés comme malveillants en 4 catégories spécifiques :
DoS, Probe, R2L, U2R.

Spécialisation sur les attaques

- **Focus exclusif** sur le trafic malveillant
- **Élimination** du bruit du trafic normal
- **Optimisation** pour discriminer les types d'attaques
- **Utilisation** d'attributs spécifiques aux menaces

Défi majeur : Déséquilibre

Classe	Ratio
DoS	883 :1
Probe	224 :1
R2L	19 :1
U2R	1 :1

Architecture utilisée

- Réseau de neurones profond
- Architecture : 41-80-40-4
- Dropout : 30% et 20%
- Activation : ReLU + Softmax


Solution : SVM-SMOTE

Application de la technique SVM-SMOTE pour :

- Générer des échantillons synthétiques
- Équilibrer toutes les classes
- Améliorer la détection des classes rares

08

SVM-SMOTE



Problème d'imbalance des classes

Conséquences du déséquilibre

- **Biais** vers les classes majoritaires
- **Sous-apprentissage** des classes rares
- **Métriques** globales trompeuses
- **Échec** de détection R2L/U2R

Ratios critiques

- DoS vs U2R : **883 :1**
- Normal vs U2R : **1295 :1**
- Probe vs U2R : **224 :1**
- R2L vs U2R : **19 :1**

Nécessité d'une solution

- Le déséquilibre critique nécessite une technique d'équilibrage sophistiquée pour améliorer la détection des classes minoritaires.

Distribution originale




Illustration du fonctionnement SVM-SMOTE

Algorithme SVM-SMOTE


Entraîner un SVM sur données déséquilibrées

Identifier les vecteurs de support de la classe minoritaire

Pour chaque vecteur de support x_i :

- Trouver ses k plus proches voisins
- Sélectionner aléatoirement x_j parmi les voisins
- Générer : $x_{\text{new}} = x_i + \lambda(x_j - x_i)$
- où $\lambda \sim \mathcal{U}(0, 1)$

Impact sur la distribution



Avantage de SVM-SMOTE

Focus sur les zones critiques (vecteurs de support) plutôt que sur tous les échantillons minoritaires.

Amélioration obtenue

- F1-macro : 0.519 → 0.601
- Amélioration : +15.6%
- Classes rares mieux représentées

09

Résultats binaire



Illustration du fonctionnement SVM-SMOTE

Observations clés

- **MLP** : Meilleures performances globales
- **SVM** : Précision maximale (97.2%)
- **Naive Bayes** : Rapidité exceptionnelle
- Trade-off temps/performance évident

Choix du modèle optimal

- Le **MLP** est sélectionné pour l'étape 1 :
- F1-score optimal (0.816)
 - Équilibre précision/rappel
 - Temps d'entraînement acceptable

Modèle	Accuracy	Précision	Rappel	F1-Score	Temps (s)
MLP	0,819	0,970	0,704	0,816	118,5
SVM	0,809	0,972	0,685	0,803	475,2
Gradient Boosting	0,790	0,968	0,652	0,779	23,3
Decision Tree	0,785	0,966	0,645	0,773	1,0
Naive Bayes	0,773	0,906	0,672	0,772	0,1
AdaBoost	0,773	0,959	0,628	0,759	11,4
Random Forest	0,763	0,968	0,603	0,743	10,7

Résultat remarquable de l'autoencodeur

Performance de l'autoencodeur

Métrique	Valeur
Accuracy	0.756
Précision	0.842
Rappel	0.664
F1-Score	0.745

Avantages de l'approche

- **Détection zero-day** : Capable d'identifier de nouvelles formes d'attaques
- **Apprentissage minimal** : Seules les données normales nécessaires
- **Adaptabilité** : Peut s'adapter à de nouveaux environnements
- **Robustesse** : Moins sensible aux biais des données d'entraînement

Performance remarquable

F1-score de **0.745** avec un modèle non-supervisé entraîné uniquement sur des données normales !

Positionnement

L'autoencodeur se classe **8ème sur 8** mais reste très compétitif avec une approche fondamentalement différente

10 Résultats multi-classes



Performances par classe d'attaque


Métriques globales

- Accuracy globale : 78.9%
- F1-macro : 60.1%
- F1-micro : 78.9%

Hiérarchie de performances

- ✓ Excellent : Normal (95.5%), DoS (86.1%)
- Acceptable : Probe (68.1%)
- ✗ Critique : R2L (14.8%), U2R (29.9%)

Classe	Précision	Rappel	F1-Score	Spécificité	Taux réussite
Normal	0.734	0.955	0.830	0.738	95.5%
DoS	0.957	0.861	0.906	0.981	86.1%
Probe	0.613	0.681	0.645	0.948	68.1%
R2L	0.907	0.148	0.254	0.998	14.8%
U2R	0.476	0.299	0.367	0.999	29.9%




Matrice de confusion et erreurs typiques

Principales confusions

- R2L → Normal : 67.8%
(Principal problème)
- Probe → Normal : 24.2%
(Confusion significative)
- R2L → Probe : 16.6%
(Similarité des signatures)
- DoS → Normal : 10.6%
(Attaques DoS subtiles)

Analyse des erreurs

Les **attaques sophistiquées** (R2L, U2R) sont souvent confondues avec le trafic normal, révélant leur **capacité de mimétisme** et la difficulté de leur détection par analyse du trafic réseau seul.



Impact de SVM-SMOTE sur les scores

Comparaison avant/après SMOTE

Métrique	Sans SMOTE	Avec SMOTE
Accuracy	0.764	0.789
F1-macro	0.519	0.601
F1-micro	0.764	0.789
Amélioration	-	+15.6%

Impact sur les classes rares

- **R2L** : F1 +23% (0.206 → 0.254)
- **U2R** : F1 +31% (0.281 → 0.367)
- **Probe** : F1 +8% (0.598 → 0.645)

Transformation des données

- Dataset original : 125,973 échantillons
- Dataset équilibré : 336,715 échantillons
- Échantillons synthétiques : 210,742
- Facteur d'augmentation : 2.67×

Validation de l'approche

L'amélioration significative du **F1-macro (+15.6%)** confirme l'efficacité de SVM-SMOTE pour traiter le déséquilibre des classes en cybersécurité.

Limites observées

- Amélioration modeste de l'accuracy globale
- Qualité limitée pour classes ultra-rares
- Nécessité de données réelles diversifiées

11

Discussion



Analyse des points forts et faibles

Points forts validés

- **Architecture hiérarchique efficace**
 - Spécialisation progressive
 - Maintenance facilitée
 - Performance optimisée
- **Autoencodeur compétitif**
 - F1 = 0.745 sans supervision
 - Détection zero-day possible
 - Apprentissage minimal requis
- **SVM-SMOTE validé**
 - +15.6% F1-macro
 - Amélioration classes rares
 - Approche sophistiquée

Limitations identifiées

- **Attaques sophistiquées**
 - R2L : 14.8% de réussite
 - U2R : 29.9% de réussite
 - Mimétisme du comportement normal
- **Dataset NSL-KDD**
 - Vieillesse (> 10 ans)
 - Non-représentatif des attaques modernes
 - Limitations de généralisation
- **Équilibrage synthétique**
 - Qualité limitée pour classes ultra-rares
 - Nécessité de diversité réelle

Comparaison avec l'état de l'art

Positionnement de nos résultats

- **Classification binaire :**
 - Notre MLP : 81.9% accuracy
 - Littérature NSL-KDD : 75–85%
 - Position : Fourchette haute
- **Classification multi-classes :**
 - Notre approche : 78.9% accuracy
 - Études récentes : 70–82%
 - Position : Compétitive

Innovations apportées :

- ✓ Architecture hiérarchique validée
- ✓ Intégration autoencodeur + supervisé
- ✓ SVM-SMOTE pour cybersécurité
- ✓ Évaluation comparative exhaustive

Contributions uniques

Méthodologie hybride : Première évaluation systématique combinant 7 algorithmes supervisés + autoencodeur

Difficultés rencontrées et solutions

Défis techniques majeurs

- **Déséquilibre extrême des classes**
 - Problème : Ratio 1295 :1 entre Normal et U2R
 - Solution : SVM-SMOTE avec +15.6% d'amélioration
 - Limitation : Qualité synthétique pour ultra-minoritaires
- **Complexité des attaques furtives**
 - Problème : R2L/U2R miment le comportement normal
 - Solution partielle : Analyse multi-niveau hiérarchique
 - Limitation : Nécessité d'approches comportementales
- **3 Optimisation des hyperparamètres**
 - Problème : Espace de recherche complexe (8 modèles)
 - Solution : Grid search + validation croisée 5-fold
 - Coût : Temps de calcul élevé

Recommandations pour déploiement

- **Approche hybride recommandée** : Notre système (Normal + DoS) + UBA (R2L) + SIEM (U2R)

11

Perspectives



Limitations identifiées

Limitations méthodologiques

- **Dataset NSL-KDD**
 - Vieillessement : > 10 ans, patterns obsolètes
 - Absence de validation multi-datasets
 - Non-représentatif des attaques IoT/Cloud modernes
- **2 Approche réseau pure**
 - Insuffisante pour attaques applicatives (R2L/U2R)
 - Absence d'analyse comportementale
 - Manque d'inspection de contenu
- **3 Généralisation temporelle**
 - Évaluation statique uniquement
 - Pas d'adaptation aux nouvelles menaces
 - Absence de mise à jour continue

Impact sur les résultats

- Ces limitations expliquent partiellement les performances critiques pour R2L (14.8%) et U2R (29.9%).

Perspectives futures prometteuses

Améliorations court terme

- **Architecture multi-niveaux**
 - 3ème étape spécialisée R2L/U2R
 - Caractéristiques dérivées temporelles
- **Explicabilité (XAI)**
 - Intégration SHAP/LIME
 - Validation par experts sécurité
- **Validation multi-datasets**
 - CICIDS-2017, UNSW-NB15
 - Robustesse cross-dataset

Améliorations court terme

- **Architecture multi-niveaux**
 - 3ème étape spécialisée R2L/U2R
 - Caractéristiques dérivées temporelles
- **Explicabilité (XAI)**
 - Intégration SHAP/LIME
 - Validation par experts sécurité
- **Validation multi-datasets**
 - CICIDS-2017, UNSW-NB15
 - Robustesse cross-dataset

Vision à long terme

- **Hybridation intelligente** d'approches automatisées et d'expertise humaine pour un cyberspace plus sûr et résilient.

12

Conclusion



Impact et recommandations pratiques

Déployabilité opérationnelle

- Système viable pour :
- ✓ Détection trafic normal (95.5%)
- ✓ Attaques DoS volumétriques (86.1%)
- Tentatives de reconnaissance (68.1%)
- Recommandations hybrid :
- Notre système (détection primaire)
- + UBA pour R2L
 - + SIEM pour U2R

Impact pour la cybersécurité

- **Méthodologie reproductible** pour la communauté
- **Identification des défis** persistants(R2L/U2R)
- **Validation empirique** de techniques d'équilibrage
- **Orientation** des recherches futures

Message clé

Cette recherche démontre la **viabilité opérationnelle** des approches ML pour la cybersécurité tout en identifiant clairement les **axes d'amélioration** pour les attaques sophistiquées.

Récapitulatif des contributions

Contributions méthodologiques principales

- Architecture hiérarchique validée
 - Spécialisation progressive optimisée
 - Classification binaire (81.9%) puis multi-classes (78.9%)
- Efficacité démontrée de l'autoencodeur
 - F1-score = 0.745 en approche non-supervisée
 - Capacité de détection zero-day validée
- Validation comparative exhaustive
 - 7 algorithmes supervisés + 1 non-supervisé évalués
 - Référentiel empirique robuste établi
- Impact quantifié de SVM-SMOTE
 - +15.6% d'amélioration F1-macro
 - Solution validée au déséquilibre des classes

Impact scientifique

- Première étude systématique combinant approche hiérarchique + autoencodeur + SVM-SMOTE pour la détection d'intrusions.

**Merci pour
votre écoute**

