



UNIVERSITÉ IBN ZOHR

FACULTÉ POLYDISCIPLINAIRE DE OUARZAZATE

Département de Mathématiques et Informatique
Spécialité : Mathématiques Appliquées pour la Science des Données

MÉMOIRE DE MASTER DE RECHERCHE

DÉTECTION ET CLASSIFICATION
D'INTRUSIONS RÉSEAU
PAR APPRENTISSAGE AUTOMATIQUE

Une Approche Hiérarchique Basée sur les Données

Présenté par

Abdelfattah BOUHLALI

Étudiant en Master
Mathématiques Appliquées pour
la Science des Données

Encadré par

Prof. Abdelkrim EL
MOUATASIM

Professeur
Département de Mathématiques
et Informatique

JURY DE SOUTENANCE

Nom	Entité	Rôle
M. Jaouad OUDAANI	Faculté Polydisciplinaire de Ouarzazate	Président
M. Rabiâ RIAD	Faculté Polydisciplinaire de Ouarzazate	Examinateur
M. Abdelkarim ELMOUATASSIM	Faculté Polydisciplinaire de Ouarzazate	Encadrant

Soutenu le : 4 Juillet 2025

Année universitaire : 2024-2025

RÉSUMÉ

Face à l'augmentation constante des cyberattaques et à l'interconnexion croissante des systèmes informatiques, le développement de systèmes de détection d'intrusions efficaces devient crucial pour la sécurité des infrastructures numériques. Cette recherche propose une approche innovante basée sur l'apprentissage automatique pour améliorer la détection et la classification des intrusions réseau.

Notre méthodologie adopte une stratégie hiérarchique en deux étapes appliquée au jeu de données NSL-KDD. La première phase réalise une classification binaire distinguant le trafic normal des activités malveillantes en combinant des algorithmes d'apprentissage supervisé avec un autoencodeur pour la détection d'anomalies. La seconde phase classe les intrusions détectées en quatre catégories : DoS, Probe, R2L et U2R. Pour traiter le déséquilibre des données, nous intégrons la technique SVM-SMOTE qui génère des échantillons synthétiques pour les classes minoritaires.

Les résultats expérimentaux démontrent la supériorité de l'autoencodeur pour la classification binaire avec une précision de 87,52%. L'application de SVM-SMOTE améliore significativement la détection des attaques sous-représentées, validant l'efficacité de notre approche hiérarchique. Cette recherche contribue au domaine de la cybersécurité en proposant une méthodologie robuste combinant apprentissage supervisé et non-supervisé pour répondre aux défis contemporains de la détection d'intrusions réseau.

Mots-clés : détection d'intrusion, apprentissage automatique, classification hiérarchique, NSL-KDD, autoencodeur, SVM-SMOTE, cybersécurité

ABSTRACT

With the exponential growth of cyber threats and the increasing interconnectivity of computer systems, developing effective intrusion detection mechanisms has become essential for protecting digital infrastructures. This research presents an innovative machine learning-based approach to enhance network intrusion detection and classification capabilities.

Our methodology employs a two-stage hierarchical strategy applied to the NSL-KDD dataset. The first stage performs binary classification to distinguish legitimate network traffic from malicious activities by combining supervised learning algorithms with an autoencoder designed for anomaly detection. The second stage categorizes detected intrusions into four attack types : DoS, Probe, R2L, and U2R. To address data imbalance issues, we integrate the SVM-SMOTE technique that generates synthetic samples for minority classes, ensuring better representation of underrepresented attack categories.

Experimental results demonstrate the superiority of the autoencoder approach for binary classification, achieving a remarkable accuracy of 87.52%. The implementation of SVM-SMOTE significantly improves detection rates for underrepresented attacks, validating the effectiveness of our hierarchical framework. This study contributes to the cybersecurity field by proposing a robust methodology that combines supervised and unsupervised learning techniques to address contemporary challenges in network intrusion detection.

Keywords : intrusion detection, machine learning, hierarchical classification, NSL-KDD, autoencoder, SVM-SMOTE, cybersecurity

REMERCIEMENTS

Au terme de ce travail de recherche, je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce mémoire.

Mes premiers remerciements s'adressent à mes chers parents, pour leur amour inconditionnel, leur soutien constant et leurs sacrifices qui ont rendu possible la réussite de mon parcours universitaire. Leur confiance en moi et leurs encouragements ont été une source de motivation permanente tout au long de cette formation.

Je remercie chaleureusement mon directeur de mémoire, **Professeur EL MOUATASIM Abdelkrim**, pour son encadrement rigoureux, ses conseils précieux et sa disponibilité. Sa guidance scientifique, ses orientations méthodologiques et son expertise dans le domaine ont été déterminantes pour mener à bien cette recherche. Je lui suis reconnaissant pour la patience dont il a fait preuve et pour la confiance qu'il m'a accordée.

Mes sincères remerciements vont également à **Madame Salma GAOU**, responsable du département de Mathématiques et Informatique, pour son leadership, son soutien administratif et pour avoir créé un environnement d'apprentissage propice à l'épanouissement académique. Sa bienveillance et ses encouragements ont grandement facilité le déroulement de cette formation.

Je souhaite également exprimer ma gratitude à l'ensemble des professeurs du département de Mathématiques et Informatique qui ont contribué à ma formation durant ces deux années de master. Leur dévouement, la qualité de leurs enseignements et leur passion pour la transmission du savoir ont enrichi mes connaissances et développé mon esprit critique dans le domaine des mathématiques appliquées et de la science des données.

Enfin, je remercie tous mes collègues de promotion pour les moments d'échange et de collaboration qui ont marqué ce parcours, ainsi que toutes les personnes qui m'ont soutenu et encouragé durant cette période d'études.

À tous, mes sincères remerciements.

Table des matières

Introduction	1
1 MÉTHODOLOGIE	2
1.1 Architecture générale du système	2
1.2 Jeu de données NSL-KDD	3
1.2.1 Présentation et structure	3
1.2.2 Description détaillée des 41 caractéristiques	3
1.2.3 Taxonomie des attaques	5
1.3 Prétraitement des données	5
1.3.1 Encodage des variables catégorielles	5
1.3.2 Normalisation des données	6
1.4 Algorithmes d'apprentissage automatique	6
1.4.1 Arbres de décision	6
1.4.2 Forêts aléatoires	7
1.4.3 Machines à vecteurs de support (SVM)	7
1.4.4 Réseaux de neurones multi-couches (MLP)	8
1.4.5 AdaBoost	9
1.5 Architecture des modèles spécialisés	10
1.5.1 Autoencodeur pour la détection d'anomalies	10
1.5.2 Réseau de neurones profond pour classification multi-classes	11
1.6 Stratégie hiérarchique	12
1.6.1 Étape 1 : Classification binaire	12
1.6.2 Étape 2 : Classification des types d'attaques	12
1.7 Gestion du déséquilibre : SVM-SMOTE	12
1.7.1 Algorithme SVM-SMOTE	12
1.8 Métriques d'évaluation	13
1.8.1 Métriques de base	13
1.8.2 Métriques agrégées	14
2 RÉSULTATS	15
2.1 Caractérisation du jeu de données NSL-KDD	15
2.1.1 Statistiques descriptives	15
2.1.2 Distribution des protocoles et services	15
2.1.3 Répartition des classes d'attaques	16
2.2 Résultats de la classification binaire	17
2.2.1 Performances comparatives des algorithmes supervisés	17
2.2.2 Évaluation de l'autoencodeur	18
2.3 Classification multi-classes avec gestion du déséquilibre	19

2.3.1	Impact de la technique SVM-SMOTE	19
2.3.2	Performances détaillées par classe d'attaque	20
2.3.3	Analyse de la matrice de confusion	21
2.4	Analyse comparative et validation	22
2.4.1	Efficacité de l'approche hiérarchique	22
2.4.2	Robustesse et généralisation	23
2.4.3	Limitations identifiées	23
2.5	Synthèse des contributions	23
3	DISCUSSION	25
3.1	Interprétation des performances obtenues	25
3.1.1	Efficacité de la classification binaire	25
3.1.2	Performance remarquable de l'autoencodeur	25
3.2	Analyse critique de la classification multi-classes	26
3.2.1	Déséquilibre des performances selon les types d'attaques	26
3.2.2	Impact et limitations de SVM-SMOTE	26
3.3	Comparaison avec l'état de l'art	27
3.3.1	Positionnement par rapport aux approches existantes	27
3.3.2	Avantages de l'approche hiérarchique	27
3.4	Implications pour la cybersécurité opérationnelle	27
3.4.1	Déployabilité et intégration en environnement de production	27
3.4.2	Stratégies de mitigation pour les classes problématiques	28
3.5	Limitations et défis identifiés	28
3.5.1	Limitations méthodologiques	28
3.5.2	Défis techniques persistants	28
3.6	Perspectives d'amélioration et recherches futures	29
3.6.1	Améliorations architecturales	29
3.6.2	Innovations méthodologiques	29
3.6.3	Directions de recherche prometteuses	30
3.7	Contributions et impact de la recherche	30
3.7.1	Contributions méthodologiques	30
3.7.2	Impact pour la communauté scientifique	30
4	CONCLUSION	31
4.1	Rappel du contexte et des objectifs	31
4.2	Synthèse des contributions principales	31
4.2.1	Architecture hiérarchique validée	32
4.2.2	Efficacité démontrée de l'autoencodeur	32
4.2.3	Validation comparative exhaustive	32
4.2.4	Impact quantifié de SVM-SMOTE	32
4.3	Principaux résultats obtenus	32
4.3.1	Excellence en classification binaire	32
4.3.2	Performances contrastées en classification multi-classes	33
4.3.3	Validation de l'approche d'équilibrage	33
4.4	Limitations reconnues et défis persistants	33
4.4.1	Contraintes liées au dataset	33
4.4.2	Défis structurels des attaques sophistiquées	33
4.4.3	Limitations de l'augmentation synthétique	33
4.5	Perspectives de recherche et recommandations	34

4.5.1	Améliorations architecturales immédiates	34
4.5.2	Innovations méthodologiques futures	34
4.5.3	Recommandations pour le déploiement opérationnel	34
4.6	Impact et contribution à la cybersécurité	35
4.7	Conclusion finale	35
Références		36

LISTE DES FIGURES

Figure 1	Architecture générale du système de détection d'intrusions hiérarchique	2
Figure 2	Distribution des classes dans le jeu de données NSL-KDD	5
Figure 3	Architecture de l'autoencodeur pour la détection d'anomalies	10
Figure 4	Illustration du processus SVM-SMOTE pour la génération d'échantillons synthétiques	13
Figure 5	Distribution des 10 principaux types de protocoles dans NSL-KDD	16
Figure 6	Comparaison des performances F1-score pour la classification binaire	17
Figure 7	Évolution des pertes d'entraînement et de validation de l'autoencodeur	18
Figure 8	Distribution des erreurs de reconstruction pour la détection d'anomalies ...	19
Figure 9	Impact de SVM-SMOTE sur la distribution des classes	20
Figure 10	Taux de réussite par classe dans la classification multi-classes	21
Figure 11	Matrice de confusion normalisée pour la classification multi-classes	22
Figure 12	Métriques détaillées par classe : Précision, Rappel et Spécificité	23

Total : 12 figures

INTRODUCTION

À l'ère du numérique, la dépendance croissante aux technologies de l'information expose nos infrastructures à des risques de sécurité considérables. L'augmentation alarmante des cyberattaques, avec des conséquences financières chiffrées en milliards d'euros, révèle l'insuffisance des systèmes de détection d'intrusions (IDS) traditionnels basés sur des signatures. Ces derniers présentent des limitations majeures, notamment leur incapacité à détecter les nouvelles formes d'attaques (zero-day).

L'apprentissage automatique offre des perspectives prometteuses pour surmonter ces défis en permettant l'apprentissage automatique à partir des données historiques et l'adaptation aux nouveaux types de menaces. Cependant, son application à la cybersécurité soulève des défis spécifiques, principalement le déséquilibre prononcé des données où les échantillons d'attaques représentent une fraction minime du trafic total.

Ce mémoire propose une approche innovante basée sur une stratégie hiérarchique d'apprentissage automatique pour la détection d'intrusions réseau, appliquée au dataset NSL-KDD. Notre méthodologie se distingue par une architecture en deux étapes : classification binaire (trafic légitime vs suspect) puis classification fine des types d'intrusions. Pour traiter le déséquilibre des classes, nous implémentons la technique SVM-SMOTE.

Les contributions principales sont : (1) la démonstration de l'efficacité d'une approche hiérarchique combinant apprentissage supervisé et non-supervisé, (2) l'évaluation comparative de différents algorithmes d'apprentissage automatique, (3) la validation de l'impact des techniques de rééquilibrage sur la détection des classes minoritaires.

Ce mémoire s'organise en quatre chapitres : méthodologie, résultats, discussion et conclusion.

Chapitre 1

MÉTHODOLOGIE

Cette section présente en détail l'approche méthodologique développée pour la détection d'intrusions réseau. Notre stratégie repose sur une architecture hiérarchique combinant apprentissage supervisé et non-supervisé, appliquée au jeu de données NSL-KDD. L'ensemble du processus, depuis le prétraitement des données jusqu'à la classification finale, est conçu pour optimiser à la fois la précision de détection et la capacité de discrimination entre les différents types d'attaques.

1.1 Architecture générale du système

Notre système de détection d'intrusions adopte une approche hiérarchique en deux étapes distinctes, illustrée dans la Figure 1.1. Cette architecture permet une analyse progressive du trafic réseau, commençant par une classification binaire robuste avant d'affiner la caractérisation des menaces détectées.




FIGURE 1.1 – Architecture générale du système de détection d'intrusions hiérarchique

La première étape effectue une discrimination fondamentale entre le trafic normal et les activités suspectes. Cette phase mobilise plusieurs algorithmes d'apprentissage automatique, incluant des approches supervisées traditionnelles et une méthode non-supervisée basée sur un autoencodeur. La seconde étape se concentre sur la classification fine des intrusions détectées, catégorisant les attaques selon quatre typologies reconnues dans la littérature scientifique.

1.2 Jeu de données NSL-KDD

1.2.1 Présentation et structure

Le jeu de données NSL-KDD constitue une version améliorée du célèbre dataset KDD Cup 99, corrigeant plusieurs limitations de son prédécesseur. Ce dataset comprend 125,973 enregistrements d'entraînement et 22,544 enregistrements de test, chaque instance étant caractérisée par 41 attributs décrivant les propriétés d'une connexion réseau.

1.2.2 Description détaillée des 41 caractéristiques

Les caractéristiques du dataset NSL-KDD se répartissent en trois catégories principales, chacune capturant des aspects différents du comportement réseau :

Caractéristiques de base (9 attributs)

Ces attributs sont directement extraits des en-têtes de paquets TCP/IP et représentent les propriétés fondamentales d'une connexion :

- **duration** : Durée de la connexion en secondes
- **protocol_type** : Type de protocole utilisé (TCP, UDP, ICMP)
- **service** : Service réseau de destination (HTTP, FTP, SMTP, etc.)
- **flag** : État normal ou d'erreur de la connexion (SF, S0, REJ, etc.)
- **src_bytes** : Nombre d'octets de données transférés de la source vers la destination
- **dst_bytes** : Nombre d'octets de données transférés de la destination vers la source
- **land** : 1 si la connexion provient et va vers le même hôte/port, 0 sinon
- **wrong_fragment** : Nombre de fragments incorrects
- **urgent** : Nombre de paquets urgents

Caractéristiques de trafic (13 attributs)

Ces statistiques sont calculées sur une fenêtre glissante de 100 connexions et analysent les patterns de comportement :

Statistiques "même hôte" :

- **count** : Nombre de connexions vers le même hôte que la connexion courante
- **srv_count** : Nombre de connexions vers le même service que la connexion courante
- **serror_rate** : Pourcentage de connexions ayant une erreur SYN
- **srv_serror_rate** : Pourcentage de connexions vers le même service ayant une erreur SYN

- **rerror_rate** : Pourcentage de connexions ayant une erreur REJ
- **srv_error_rate** : Pourcentage de connexions vers le même service ayant une erreur REJ
- **same_srv_rate** : Pourcentage de connexions vers le même service
- **diff_srv_rate** : Pourcentage de connexions vers différents services

Statistiques "hôte de destination" :

- **dst_host_count** : Nombre de connexions ayant le même hôte de destination
- **dst_host_srv_count** : Nombre de connexions ayant le même service de destination
- **dst_host_same_srv_rate** : Pourcentage de connexions vers le même service de destination
- **dst_host_diff_srv_rate** : Pourcentage de connexions vers différents services de destination
- **dst_host_same_src_port_rate** : Pourcentage de connexions utilisant le même port source

Caractéristiques de contenu (19 attributs)

Ces attributs analysent le contenu des paquets et sont particulièrement utiles pour détecter les attaques R2L et U2R :

Indicateurs d'accès privilégié :

- **hot** : Nombre d'indicateurs "hot" (accès à fichiers/répertoires sensibles)
- **num_failed_logins** : Nombre de tentatives de connexion échouées
- **logged_in** : 1 si connecté avec succès, 0 sinon
- **num_compromised** : Nombre de conditions "compromised"
- **root_shell** : 1 si un shell root a été obtenu, 0 sinon
- **su_attempted** : 1 si une commande "su root" a été tentée, 0 sinon

Statistiques d'accès aux fichiers :

- **num_root** : Nombre d'accès "root"
- **num_file_creations** : Nombre d'opérations de création de fichiers
- **num_shells** : Nombre d'invitations de commandes shell
- **num_access_files** : Nombre d'opérations d'accès aux fichiers de contrôle
- **num_outbound_cmds** : Nombre de commandes sortantes dans une session FTP

Indicateurs de session :

- **is_host_login** : 1 si le login appartient à la liste "hot", 0 sinon
- **is_guest_login** : 1 si le login est "guest", 0 sinon

Statistiques d'erreur de destination :

- **dst_host_srv_diff_host_rate** : Pourcentage de connexions vers différents hôtes
- **dst_host_serror_rate** : Pourcentage de connexions ayant une erreur SYN
- **dst_host_srv_serror_rate** : Pourcentage de connexions vers le même service ayant une erreur SYN
- **dst_host_rerror_rate** : Pourcentage de connexions ayant une erreur REJ
- **dst_host_srv_rerror_rate** : Pourcentage de connexions vers le même service ayant une erreur REJ

1.2.3 Taxonomie des attaques

NSL-KDD organise les intrusions selon quatre catégories principales, chacune représentant un mode opératoire distinct :

TABLE 1.1 – Distribution des catégories d’attaques dans NSL-KDD

Catégorie	Description	Exemples
DoS	Attaques par déni de service visant à saturer les ressources	neptune, smurf, pod
Probe	Tentatives de reconnaissance pour découvrir les vulnérabilités	satan, portsweep, nmap
R2L	Intrusions distantes cherchant un accès local non autorisé	warezclient, imap, spy
U2R	Élévations de privilèges d’utilisateur vers administrateur	buffer_overflow, rootkit




FIGURE 1.2 – Distribution des classes dans le jeu de données NSL-KDD

1.3 Prétraitement des données

1.3.1 Encodage des variables catégorielles

Le jeu de données NSL-KDD contient trois attributs catégoriels : le type de protocole, le service réseau et l’état de la connexion. Ces variables textuelles nécessitent une transformation numérique pour être exploitables par les algorithmes d’apprentissage automatique.

Nous appliquons un encodage par fréquence (Label Frequency Encoding) qui attribue des valeurs numériques en fonction de la fréquence d’apparition de chaque catégorie. Pour une variable catégorielle X avec des catégories $\{c_1, c_2, \dots, c_k\}$, l’encodage par fréquence assigne à chaque catégorie c_i la valeur :

$$\text{encoded}(c_i) = \text{rank}(\text{freq}(c_i)) \quad (1.1)$$

où $\text{freq}(c_i)$ représente la fréquence d'apparition de la catégorie c_i et rank attribue un rang basé sur cette fréquence.

1.3.2 Normalisation des données

La standardisation des caractéristiques numériques constitue une étape cruciale pour assurer l'efficacité des algorithmes d'apprentissage automatique. Nous appliquons la standardisation Z-score :

$$z_i = \frac{x_i - \mu}{\sigma} \quad (1.2)$$

où x_i représente la valeur originale, μ la moyenne arithmétique et σ l'écart-type de la caractéristique considérée.

1.4 Algorithmes d'apprentissage automatique

1.4.1 Arbres de décision

Les arbres de décision constituent une famille d'algorithmes d'apprentissage supervisé particulièrement adaptée à l'interprétabilité. Un arbre de décision partitionne récursivement l'espace des caractéristiques en utilisant des tests binaires sur les attributs.

Critère de division

Pour construire l'arbre, nous utilisons le critère d'entropie. L'entropie d'un ensemble S est définie par :

$$H(S) = - \sum_{i=1}^c p_i \log_2(p_i) \quad (1.3)$$

où c est le nombre de classes et p_i la proportion d'exemples de classe i dans S .

Le gain d'information pour un attribut A divisant S en sous-ensembles $\{S_1, S_2, \dots, S_v\}$ est :

$$\text{Gain}(S, A) = H(S) - \sum_{j=1}^v \frac{|S_j|}{|S|} H(S_j) \quad (1.4)$$

Critère d'arrêt

L'algorithme s'arrête lorsque :

- Tous les exemples appartiennent à la même classe
- La profondeur maximale est atteinte
- Le nombre minimum d'exemples par feuille est atteint
- Le gain d'information est inférieur à un seuil prédéfini

1.4.2 Forêts aléatoires

Les forêts aléatoires combinent plusieurs arbres de décision selon le principe du bagging (Bootstrap AGGREGatING). Cette méthode d'ensemble améliore la robustesse et la généralisation.

Algorithme de construction

Pour construire une forêt de T arbres :

1. Pour $t = 1$ à T :
 - Générer un échantillon bootstrap S_t de taille n avec remise
 - À chaque nœud, sélectionner aléatoirement m caractéristiques parmi les p disponibles (généralement $m = \sqrt{p}$)
 - Construire l'arbre h_t en utilisant S_t et les m caractéristiques sélectionnées

Prédiction

La prédiction finale est obtenue par vote majoritaire pour la classification :

$$\hat{y} = \text{mode}\{h_1(\mathbf{x}), h_2(\mathbf{x}), \dots, h_T(\mathbf{x})\} \quad (1.5)$$

La probabilité de classe k est estimée par :

$$\hat{p}_k(\mathbf{x}) = \frac{1}{T} \sum_{t=1}^T \mathbb{I}(h_t(\mathbf{x}) = k) \quad (1.6)$$

où $\mathbb{I}$ est la fonction indicatrice.

1.4.3 Machines à vecteurs de support (SVM)

Les SVM recherchent l'hyperplan optimal séparant les classes en maximisant la marge entre les points les plus proches de chaque classe.

Formulation mathématique

Pour un problème de classification binaire avec des données linéairement séparables, l'objectif est de trouver l'hyperplan $\mathbf{w}^T \mathbf{x} + b = 0$ qui maximise la marge.

Le problème d'optimisation s'écrit :

$$\min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2 \quad (1.7)$$

$$\text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, n \quad (1.8)$$

Cas non-linéairement séparable

Pour traiter les cas non-linéairement séparables, nous introduisons des variables de relaxation ξ_i :

$$\min_{\mathbf{w}, b, \xi} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad (1.9)$$

$$\text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad (1.10)$$

$$\xi_i \geq 0, \quad i = 1, \dots, n \quad (1.11)$$

où C est le paramètre de régularisation contrôlant le compromis entre la maximisation de la marge et la minimisation des erreurs de classification.

Noyau RBF

Pour capturer les relations non-linéaires, nous utilisons le noyau gaussien (RBF) :

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (1.12)$$

où γ contrôle l'influence de chaque exemple d'entraînement.

1.4.4 Réseaux de neurones multi-couches (MLP)

Le perceptron multi-couches est un réseau de neurones feedforward capable d'apprendre des relations non-linéaires complexes.

Architecture

Notre MLP comprend :

- Couche d'entrée : 41 neurones
- Couche cachée : 100 neurones avec activation ReLU
- Couche de sortie : 2 neurones avec activation softmax (classification binaire)

Fonction d'activation ReLU

La fonction ReLU (Rectified Linear Unit) est définie par :

$$\text{ReLU}(x) = \max(0, x) \quad (1.13)$$

Fonction softmax

Pour la couche de sortie, la fonction softmax normalise les sorties en probabilités :

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (1.14)$$

Propagation avant

Pour une couche l , le calcul s'effectue selon :

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)} \quad (1.15)$$

$$\mathbf{a}^{(l)} = f(\mathbf{z}^{(l)}) \quad (1.16)$$

où $\mathbf{W}^{(l)}$ et $\mathbf{b}^{(l)}$ sont respectivement la matrice de poids et le vecteur de biais de la couche l , et f est la fonction d'activation.

Fonction de coût

Nous utilisons l'entropie croisée comme fonction de coût :

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \sum_{k=1}^K y_k^{(i)} \log(\hat{y}_k^{(i)}) \quad (1.17)$$

Rétropropagation

Les gradients sont calculés par rétropropagation :

$$\frac{\partial J}{\partial \mathbf{W}^{(l)}} = \frac{1}{m} \boldsymbol{\delta}^{(l)} (\mathbf{a}^{(l-1)})^T \quad (1.18)$$

$$\frac{\partial J}{\partial \mathbf{b}^{(l)}} = \frac{1}{m} \sum_{i=1}^m \boldsymbol{\delta}^{(l)} \quad (1.19)$$

où $\boldsymbol{\delta}^{(l)}$ est l'erreur de la couche l .

1.4.5 AdaBoost

AdaBoost (Adaptive Boosting) est une méthode d'ensemble qui combine séquentiellement des classificateurs faibles en se concentrant sur les exemples difficiles à classifier.

Algorithme AdaBoost

1. Initialiser les poids : $w_1^{(i)} = \frac{1}{m}$ pour $i = 1, \dots, m$
2. Pour $t = 1$ à T :
 - (a) Entraîner un classificateur faible h_t sur la distribution w_t
 - (b) Calculer l'erreur pondérée :

$$\epsilon_t = \sum_{i=1}^m w_t^{(i)} \mathbb{I}(y_i \neq h_t(\mathbf{x}_i)) \quad (1.20)$$

- (c) Calculer le coefficient :

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right) \quad (1.21)$$

- (d) Mettre à jour les poids :

$$w_{t+1}^{(i)} = \frac{w_t^{(i)} \exp(-\alpha_t y_i h_t(\mathbf{x}_i))}{Z_t} \quad (1.22)$$

où Z_t est le facteur de normalisation

3. Le classificateur final est :

$$H(\mathbf{x}) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(\mathbf{x}) \right) \quad (1.23)$$

1.5 Architecture des modèles spécialisés

1.5.1 Autoencodeur pour la détection d'anomalies

L'autoencodeur constitue l'élément central de notre approche non-supervisée pour la classification binaire.




FIGURE 1.3 – Architecture de l'autoencodeur pour la détection d'anomalies

Architecture

Notre autoencodeur se compose de :

- **Couche d'entrée** : 41 neurones avec bruit gaussien $\mathcal{N}(0, 0.15^2)$
- **Couche d'encodage** : 15 neurones avec activation SELU et dropout (5%)
- **Couche de décodage** : 41 neurones avec activation SELU

Fonction d'activation SELU

La fonction SELU (Scaled Exponential Linear Unit) est définie par :

$$\text{SELU}(x) = \lambda \begin{cases} x & \text{si } x > 0 \\ \alpha(e^x - 1) & \text{si } x \leq 0 \end{cases} \quad (1.24)$$

avec $\alpha = 1.6732632423543772$ et $\lambda = 1.0507009873554805$.

Fonction de coût

L'erreur quadratique moyenne (MSE) est utilisée comme fonction de coût :

$$\mathcal{L}_{\text{MSE}} = \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2 \quad (1.25)$$

Détection d'anomalies

L'erreur de reconstruction pour un échantillon $\mathbf{x}$ est :

$$\text{erreur_reconstruction}(\mathbf{x}) = \|\mathbf{x} - \hat{\mathbf{x}}\|^2 \quad (1.26)$$

Le seuil de détection est défini comme le 95ème percentile des erreurs de reconstruction sur les données normales :

$$\tau = \text{percentile}_{95}(\{\text{erreur_reconstruction}(\mathbf{x}_i) : y_i = \text{normal}\}) \quad (1.27)$$

1.5.2 Réseau de neurones profond pour classification multi-classes

Architecture

Le DNN comprend :

- **Couche d'entrée** : 41 neurones
- **Première couche cachée** : 80 neurones, ReLU, dropout (30%)
- **Seconde couche cachée** : 40 neurones, ReLU, dropout (20%)
- **Couche de sortie** : 4 neurones, softmax

Fonction de coût

L'entropie croisée sparse est utilisée :

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \log(p_{y_i}) \quad (1.28)$$

1.6 Stratégie hiérarchique

1.6.1 Étape 1 : Classification binaire

La première étape distingue le trafic normal des activités malveillantes. Nous évaluons tous les algorithmes présentés et sélectionnons le plus performant.

1.6.2 Étape 2 : Classification des types d'attaques

Cette étape utilise uniquement les échantillons classifiés comme malveillants, permettant une spécialisation sur la discrimination entre types d'attaques.

1.7 Gestion du déséquilibre : SVM-SMOTE

1.7.1 Algorithme SVM-SMOTE

SVM-SMOTE améliore SMOTE en utilisant un SVM pour identifier les échantillons critiques :

1. Entraîner un SVM sur les données déséquilibrées
2. Identifier les vecteurs de support de la classe minoritaire
3. Pour chaque vecteur de support $\mathbf{x}_i$:
 - (a) Trouver ses k plus proches voisins de la même classe
 - (b) Générer des échantillons synthétiques par interpolation :

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda \cdot (\mathbf{x}_j - \mathbf{x}_i) \quad (1.29)$$

où $\lambda \sim \mathcal{U}(0, 1)$ et $\mathbf{x}_j$ est un voisin choisi aléatoirement




FIGURE 1.4 – Illustration du processus SVM-SMOTE

1.8 Métriques d'évaluation

1.8.1 Métriques de base

$$\text{Précision} = \frac{TP}{TP + FP} \quad (1.30)$$

$$\text{Rappel} = \frac{TP}{TP + FN} \quad (1.31)$$

$$\text{F1-score} = \frac{2 \times \text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}} \quad (1.32)$$

$$\text{Exactitude} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1.33)$$

1.8.2 Métriques agrégées

$$\text{F1-macro} = \frac{1}{K} \sum_{k=1}^K \text{F1-score}_k \quad (1.34)$$

$$\text{F1-micro} = \frac{2 \times \text{Précision}_{\text{micro}} \times \text{Rappel}_{\text{micro}}}{\text{Précision}_{\text{micro}} + \text{Rappel}_{\text{micro}}} \quad (1.35)$$

Cette méthodologie complète assure une évaluation rigoureuse et reproductible de notre système de détection d'intrusions hiérarchique.

Chapitre 2

RÉSULTATS

Cette section présente l'évaluation exhaustive de notre système de détection d'intrusions hiérarchique appliqué au jeu de données NSL-KDD. Les résultats sont organisés selon notre méthodologie en deux étapes : classification binaire suivie de la classification multi-classes. Une analyse détaillée des performances, incluant l'impact des techniques d'équilibrage et les limitations identifiées, complète cette évaluation.

2.1 Caractérisation du jeu de données NSL-KDD

2.1.1 Statistiques descriptives

Le dataset NSL-KDD utilisé dans nos expérimentations comprend 125,973 échantillons d'entraînement et 22,544 échantillons de test, chacun caractérisé par 40 attributs après préprocessing. Le Tableau 2.1 résume les propriétés principales du jeu de données.

TABLE 2.1 – Caractéristiques générales du dataset NSL-KDD

Dataset	Échantillons	Caractéristiques	Valeurs manquantes
Entraînement	125,973	40	0
Test	22,544	40	0

La répartition des 40 caractéristiques révèle une prédominance des variables numériques (37 attributs) par rapport aux variables catégorielles (3 attributs), facilitant l'application des algorithmes d'apprentissage automatique.

2.1.2 Distribution des protocoles et services

L'analyse révèle une forte concentration sur quelques protocoles majoritaires. HTTP domine avec 40,338 occurrences (32,0%), suivi par les connexions privées (21,853, 17,3%) et domain_u (9,043, 7,2%). Cette distribution reflète les patterns typiques du trafic réseau réel, où certains services génèrent la majorité des connexions.




FIGURE 2.1 – Distribution des 10 principaux types de protocoles dans NSL-KDD

L'analyse des états de connexion (flags) montre une prédominance des connexions réussies (SF : 59,5%) et des connexions refusées ou interrompues (S0 : 27,7%, REJ : 8,9%), cohérente avec les comportements attendus dans un environnement réseau mixte incluant des tentatives d'intrusion.

2.1.3 Répartition des classes d'attaques

La distribution des classes dans le dataset d'entraînement révèle un équilibre relatif entre le trafic normal (67,343 échantillons, 53,5%) et les attaques (58,630 échantillons, 46,5%). Cependant, l'analyse des sous-catégories d'attaques révèle un déséquilibre significatif :

TABLE 2.2 – Distribution des classes dans les datasets d'entraînement et de test

Classe	Entraînement		Test	
	Échantillons	%	Échantillons	%
Normal	67,343	53,5	9,711	43,1
DoS	45,927	36,5	7,458	33,1
Probe	11,656	9,3	2,421	10,7
R2L	995	0,8	2,887	12,8
U2R	52	0,0	67	0,3

Cette distribution révèle un déséquilibre critique avec un ratio de 1295 :1 entre la classe majoritaire (Normal) et minoritaire (U2R), justifiant l'application de techniques d'équilibrage pour améliorer la détection des classes sous-représentées.

2.2 Résultats de la classification binaire

2.2.1 Performances comparatives des algorithmes supervisés

L'évaluation de sept algorithmes d'apprentissage supervisé pour la classification binaire révèle des performances variables selon les métriques considérées. Le Tableau 2.3 présente les résultats détaillés.

TABLE 2.3 – Performances des modèles de classification binaire

Modèle	Accuracy	Précision	Rappel	F1-Score	Temps (s)
MLP	0,819	0,970	0,704	0,816	118,5
SVM	0,809	0,972	0,685	0,803	475,2
Gradient Boosting	0,790	0,968	0,652	0,779	23,3
Decision Tree	0,785	0,966	0,645	0,773	1,0
Naive Bayes	0,773	0,906	0,672	0,772	0,1
AdaBoost	0,773	0,959	0,628	0,759	11,4
Random Forest	0,763	0,968	0,603	0,743	10,7

Le perceptron multi-couches (MLP) démontre les meilleures performances globales avec un F1-score de 0,816 et une accuracy de 0,819. Cette supériorité s'explique par la capacité des réseaux de neurones à capturer les relations non-linéaires complexes présentes dans les données de trafic réseau. Le SVM obtient la meilleure précision (0,972) mais avec un rappel plus faible, indiquant une tendance conservatrice dans la détection d'intrusions.




FIGURE 2.2 – Comparaison des performances F1-score pour la classification binaire

Naive Bayes optimise le temps/performance (0,1s, F1=0,772) tandis que SVM nécessite 475,2s malgré d'excellentes performances.

2.2.2 Évaluation de l'autoencodeur

L'autoencodeur, représentant notre approche non-supervisée, atteint des performances remarquables avec un F1-score de 0,745 et une accuracy de 0,756. Ces résultats sont particulièrement significatifs considérant que le modèle est entraîné uniquement sur des données normales.

Processus d'entraînement

L'entraînement de l'autoencodeur s'est achevé après 37 époques avec convergence stable. La perte finale d'entraînement ($MSE = 0,106$) et de validation ($MSE = 0,054$) indiquent une bonne généralisation sans surapprentissage.




FIGURE 2.3 – Évolution des pertes d'entraînement et de validation de l'autoencodeur

Détermination du seuil optimal

Le seuil de détection d'anomalies, fixé au 95ème percentile des erreurs de reconstruction sur les données normales, s'établit à 0,1696. Cette valeur optimise le compromis entre sensibilité et spécificité pour la détection d'intrusions.




FIGURE 2.4 – Distribution des erreurs de reconstruction pour la détection d’anomalies

L’analyse de la distribution des erreurs de reconstruction montre une séparation claire entre les patterns normaux (moyenne = 0,061) et les attaques (moyenne = 0,421), validant l’efficacité de l’approche par autoencodeur pour la détection d’anomalies.

2.3 Classification multi-classes avec gestion du dés-équilibre

2.3.1 Impact de la technique SVM-SMOTE

L’application de SVM-SMOTE transforme radicalement la distribution des classes d’entraînement, passant de 125,973 à 336,715 échantillons. Cette augmentation de 210,742 échantillons synthétiques rééquilibre toutes les classes minoritaires au niveau de la classe majoritaire (67,343 échantillons chacune).




FIGURE 2.5 – Impact de SVM-SMOTE sur la distribution des classes

L'évaluation comparative révèle l'efficacité de cette technique :

TABLE 2.4 – Impact de SVM-SMOTE sur les performances

Configuration	Accuracy	F1-macro	Amélioration
Sans SMOTE	0,764	0,519	-
Avec SMOTE	0,789	0,601	+3,3% / +15,6%

L'amélioration du F1-score macro (+15,6%) démontre l'efficacité particulière de SMOTE pour les classes minoritaires, bien que l'amélioration de l'accuracy globale reste modeste (+3,3%).

2.3.2 Performances détaillées par classe d'attaque

Le réseau de neurones profond entraîné sur les données équilibrées atteint une accuracy globale de 0,789 avec un F1-macro de 0,601. L'analyse détaillée par classe révèle des performances hétérogènes :

TABLE 2.5 – Métriques détaillées par classe d'attaque

Classe	Précision	Rappel	F1-Score	Spécificité	Taux réussite
Normal	0,734	0,955	0,830	0,738	95,5%
DoS	0,957	0,861	0,906	0,981	86,1%
Probe	0,613	0,681	0,645	0,948	68,1%
R2L	0,907	0,148	0,254	0,998	14,8%
U2R	0,476	0,299	0,367	0,999	29,9%




FIGURE 2.6 – Taux de réussite par classe dans la classification multi-classes

Les résultats révèlent une hiérarchie claire de performances :

- **Excellente** : Normal (95,5%) - Détection quasi-parfaite du trafic légitime
- **Bonne** : DoS (86,1%) - Identification efficace des attaques volumétriques
- **Acceptable** : Probe (68,1%) - Détection modérée des tentatives de reconnaissance
- **Critique** : R2L (14,8%) et U2R (29,9%) - Performances insuffisantes pour les attaques sophistiquées

2.3.3 Analyse de la matrice de confusion

La matrice de confusion normalisée (Figure 2.7) révèle les patterns de classification erronée les plus problématiques :




FIGURE 2.7 – Matrice de confusion normalisée pour la classification multi-classes

L'analyse des confusions principales identifie :

- **R2L** → **Normal** : 1,956 cas (67,8%) - Principale source d'erreur
- **Probe** → **Normal** : 587 cas (24,2%) - Confusion significative
- **R2L** → **Probe** : 478 cas (16,6%) - Similarité des signatures de reconnaissance
- **DoS** → **Normal** : 794 cas (10,6%) - Erreurs sur attaques DoS subtiles

Ces patterns révèlent la difficulté particulière à distinguer les attaques sophistiquées (R2L, U2R) du trafic normal, nécessitant des approches spécialisées pour ces classes critiques.

2.4 Analyse comparative et validation

2.4.1 Efficacité de l'approche hiérarchique

L'architecture hiérarchique proposée démontre sa pertinence par la spécialisation progressive des modèles. La première étape (classification binaire) atteint d'excellentes performances globales ($F1 = 0,816$), tandis que la seconde étape permet une caractérisation fine des types d'attaques malgré les défis posés par le déséquilibre des classes.




FIGURE 2.8 – Métriques détaillées par classe : Précision, Rappel et Spécificité

2.4.2 Robustesse et généralisation

L'évaluation de la robustesse révèle des performances cohérentes entre les datasets d'entraînement et de test, indiquant une bonne capacité de généralisation. Les écarts observés (notamment pour les classes R2L et U2R) s'expliquent principalement par les différences de distribution entre les datasets plutôt que par un surapprentissage.

2.4.3 Limitations identifiées

Notre analyse révèle trois limitations principales :

1. **Détection des attaques sophistiquées** : Les attaques R2L et U2R, caractérisées par des signatures subtiles, demeurent difficiles à détecter avec les techniques actuelles.
2. **Déséquilibre résiduel** : Malgré l'application de SVM-SMOTE, la qualité des échantillons synthétiques pour les classes ultra-minoritaires reste limitée.
3. **Généralisation temporelle** : L'évaluation sur NSL-KDD, bien que standard, ne garantit pas les performances sur des attaques contemporaines.

2.5 Synthèse des contributions

Nos expérimentations démontrent plusieurs contributions significatives :

- **Validation de l'approche hiérarchique** : L'architecture en deux étapes optimise les performances en permettant une spécialisation progressive.
- **Efficacité de l'autoencodeur** : L'approche non-supervisée atteint des performances compétitives ($F1 = 0,745$) pour la détection binaire.
- **Impact positif de SVM-SMOTE** : L'amélioration de 15,6% du F1-macro confirme l'intérêt des techniques d'équilibrage pour les classes minoritaires.
- **Identification des défis persistants** : La caractérisation précise des limitations oriente les développements futurs.

Les résultats obtenus positionnent notre système comme une solution viable pour la détection d'intrusions en environnement opérationnel, avec des performances particulièrement remarquables pour les attaques volumétriques (DoS) et le trafic normal, tout en identifiant clairement les axes d'amélioration pour les attaques sophistiquées.

Chapitre 3

DISCUSSION

Cette section analyse et interprète les résultats expérimentaux présentés précédemment, en examinant leurs implications pour la cybersécurité, leurs limites et les perspectives d'amélioration. Nous contextualisons nos contributions par rapport à l'état de l'art et discutons des défis spécifiques rencontrés dans la détection d'intrusions par apprentissage automatique.

3.1 Interprétation des performances obtenues

3.1.1 Efficacité de la classification binaire

Les performances remarquables du perceptron multi-couches (MLP) en classification binaire (F1-score = 0,816, accuracy = 0,819) s'expliquent par plusieurs facteurs convergents. Premièrement, l'architecture multi-couches permet l'apprentissage de représentations hiérarchiques complexes, capturant des patterns d'interaction entre caractéristiques que les modèles linéaires ne peuvent identifier. Cette capacité s'avère particulièrement précieuse pour discriminer les comportements réseau subtils qui distinguent les intrusions du trafic légitime.

La supériorité du MLP sur les méthodes d'ensemble (Random Forest, AdaBoost) suggère que la non-linéarité inhérente aux données de trafic réseau nécessite des approches capables de modéliser des relations complexes plutôt que des combinaisons linéaires de règles simples. Cette observation aligne nos résultats avec les tendances actuelles privilégiant l'apprentissage profond pour les tâches de cybersécurité.

L'excellente précision du SVM (0,972) confirme sa robustesse théorique pour les problèmes de classification binaire, mais son rappel plus faible (0,685) révèle une tendance conservatrice potentiellement problématique en contexte sécuritaire. Cette caractéristique, bien qu'elle minimise les faux positifs, peut conduire à manquer des intrusions réelles, un risque inacceptable dans la plupart des environnements de production.

3.1.2 Performance remarquable de l'autoencodeur

L'autoencodeur démontre des performances surprenantes (F1-score = 0,745) considérant son entraînement exclusivement sur des données normales. Cette efficacité valide l'hypothèse fondamentale de la détection d'anomalies : les patterns d'intrusion, par leur nature même, s'écartent suffisamment des comportements normaux pour être identifiées par leurs erreurs de reconstruction.

La convergence stable après 37 époques (perte finale = 0,106) indique une architecture bien dimensionnée évitant le surapprentissage. La séparation claire des distributions d'erreurs entre trafic normal (moyenne = 0,061) et attaques (moyenne = 0,421) démontre la capacité de l'autoencodeur à créer une représentation interne discriminante des patterns légitimes.

Cette approche présente l'avantage stratégique de ne pas nécessiter d'exemples d'attaques pour l'entraînement, offrant une capacité théorique de détection de nouvelles formes d'intrusions non présentes dans les données historiques. Cette propriété s'avère cruciale face à l'évolution constante des techniques d'attaque.

3.2 Analyse critique de la classification multi-classes

3.2.1 Déséquilibre des performances selon les types d'attaques

Les résultats de classification multi-classes révèlent une hiérarchie de détectabilité directement corrélée aux caractéristiques intrinsèques de chaque type d'attaque. La détection excellente du trafic normal (95,5%) et des attaques DoS (86,1%) contraste fortement avec les performances critiques pour R2L (14,8%) et U2R (29,9%).

Cette disparité s'explique par la nature même de ces attaques. Les attaques DoS, par définition, génèrent des volumes de trafic anormaux facilement identifiables par les caractéristiques statistiques (count, srv_count, connection rates). Les algorithmes d'apprentissage automatique excellent dans la détection de ces anomalies volumétriques qui créent des signatures distinctives dans l'espace des caractéristiques.

À l'inverse, les attaques R2L et U2R sont conçues pour mimer le comportement normal tout en exploitant des vulnérabilités subtiles. Ces intrusions se caractérisent par leur discrétion : elles utilisent des connexions apparemment légitimes et exploitent des failles logicielles ou de configuration plutôt que des anomalies de trafic. Cette furtivité explique pourquoi 67,8% des attaques R2L sont incorrectement classifiées comme trafic normal.

3.2.2 Impact et limitations de SVM-SMOTE

L'amélioration de 15,6% du F1-score macro grâce à SVM-SMOTE valide l'efficacité des techniques d'équilibrage pour les classes minoritaires. Cette amélioration démontre que le déséquilibre initial (ratio 1295 :1) constituait effectivement un obstacle majeur à l'apprentissage des patterns discriminants pour les classes sous-représentées.

Cependant, l'amélioration modeste de l'accuracy globale (+3,3%) révèle une limitation fondamentale : la génération d'échantillons synthétiques ne peut compenser entièrement l'absence de diversité dans les exemples réels d'attaques R2L et U2R. Les 52 échantillons U2R originaux, même multipliés synthétiquement, ne capturent probablement qu'une fraction limitée de la variabilité réelle de cette classe d'attaques.

Cette observation souligne un défi méthodologique plus large : l'efficacité des techniques d'augmentation de données dépend crucialement de la richesse et de la représentativité des échantillons originaux. Pour des classes ultra-minoritaires comme U2R, la collecte de données réelles diversifiées demeure un prérequis à toute amélioration significative des performances.

3.3 Comparaison avec l'état de l'art

3.3.1 Positionnement par rapport aux approches existantes

Nos résultats se positionnent favorablement par rapport aux études récentes sur NSL-KDD. L'accuracy de 0,819 en classification binaire et 0,789 en multi-classes s'inscrit dans la fourchette haute des performances rapportées dans la littérature pour ce dataset. Cette comparaison doit cependant être nuancée par les différences méthodologiques entre études (preprocessing, métriques d'évaluation, validation croisée).

L'originalité de notre approche réside dans la combinaison d'une architecture hiérarchique avec l'intégration d'un autoencodeur et de techniques d'équilibrage avancées. Peu d'études explorent systématiquement cette synergie, la plupart se concentrant sur l'optimisation d'algorithmes individuels plutôt que sur l'architecture globale du système de détection.

L'utilisation de SVM-SMOTE, plutôt que de SMOTE classique, constitue une innovation méthodologique justifiée par nos résultats. Cette technique plus sophistiquée génère des échantillons synthétiques dans les régions critiques de l'espace des caractéristiques, améliorant la qualité de l'augmentation de données par rapport aux approches naïves.

3.3.2 Avantages de l'approche hiérarchique

L'architecture hiérarchique démontre des bénéfices tangibles par rapport aux approches de classification directe en 5 classes. La spécialisation progressive permet d'optimiser chaque étape pour sa tâche spécifique : la première étape maximise la sensibilité à toute forme d'intrusion, tandis que la seconde affine la caractérisation des menaces détectées.

Cette décomposition présente également des avantages opérationnels significatifs. En contexte de production, la classification binaire peut déclencher des alertes immédiates, tandis que la classification fine guide la réponse spécialisée. Cette hiérarchisation des alertes optimise l'allocation des ressources humaines et techniques de sécurité.

De plus, l'architecture hiérarchique facilite la maintenance et l'évolution du système. Chaque étape peut être optimisée, mise à jour ou remplacée indépendamment, offrant une flexibilité architecturale supérieure aux approches monolithiques.

3.4 Implications pour la cybersécurité opérationnelle

3.4.1 Déployabilité et intégration en environnement de production

Les performances obtenues, particulièrement pour la détection du trafic normal (95,5%) et des attaques DoS (86,1%), positionnent notre système comme viable pour un déploiement opérationnel. Ces niveaux de performance réduisent significativement les faux positifs tout en maintenant une sensibilité élevée aux menaces volumétriques, optimisant ainsi l'efficacité des équipes de sécurité.

L'autoencodeur présente un intérêt particulier pour les environnements dynamiques où de nouveaux types d'attaques émergent régulièrement. Sa capacité à détecter des

anomalies sans connaissance préalable des patterns d’attaque offre une couverture prophylactique contre les menaces zero-day, complément essentiel aux approches supervisées traditionnelles.

Le temps d’entraînement du MLP (118,5 secondes) et la rapidité d’inférence des réseaux de neurones permettent un déploiement en temps réel dans la plupart des environnements réseau contemporains. Cette efficacité computationnelle facilite l’intégration dans les architectures de sécurité existantes sans impact significatif sur les performances réseau.

3.4.2 Stratégies de mitigation pour les classes problématiques

Les performances critiques pour R2L et U2R nécessitent des stratégies compensatoires en environnement opérationnel. Nous recommandons une approche hybride combinant notre système automatisé avec des techniques de détection spécialisées pour ces classes d’attaques.

Pour les attaques R2L, l’intégration d’analyses comportementales des utilisateurs (UBA - User Behavior Analytics) peut compléter efficacement la détection basée sur le trafic réseau. Ces attaques, caractérisées par l’exploitation de comptes légitimes, génèrent souvent des patterns comportementaux anormaux détectables par l’analyse des habitudes utilisateur.

Les attaques U2R, exploitant des vulnérabilités système pour l’élévation de privilèges, nécessitent une surveillance spécialisée des événements système et de sécurité. L’intégration de SIEM (Security Information et Event Management) analysant les logs système peut détecter les tentatives d’élévation de privilèges que notre approche réseau ne capture pas.

3.5 Limitations et défis identifiés

3.5.1 Limitations méthodologiques

Notre évaluation, bien que rigoureuse, présente plusieurs limitations inhérentes à l’utilisation du dataset NSL-KDD. Ce dataset, malgré ses améliorations par rapport à KDD’99, date de plus d’une décennie et ne reflète pas nécessairement les patterns d’attaque contemporains. L’évolution rapide des techniques d’intrusion soulève des questions sur la généralisation temporelle de nos résultats.

La nature statique du dataset ne permet pas d’évaluer la capacité d’adaptation du système face à l’évolution des menaces. En environnement réel, les attaquants adaptent constamment leurs techniques pour contourner les systèmes de détection, nécessitant une réévaluation continue des modèles.

L’absence de validation croisée sur d’autres datasets (CICIDS-2017, UNSW-NB15) limite la généralisation de nos conclusions. Cette limitation méthodologique, commune à de nombreuses études sur NSL-KDD, souligne le besoin d’évaluations multi-datasets pour valider la robustesse des approches proposées.

3.5.2 Défis techniques persistants

Le défi fondamental de la détection des attaques sophistiquées (R2L, U2R) transcende les limitations de notre approche spécifique. Ces intrusions, par conception, ex-

exploitent des vulnérabilités logiques plutôt que des anomalies de trafic, nécessitant des approches de détection fondamentalement différentes.

L’analyse de contenu applicatif, l’inspection de protocoles et l’analyse comportementale longitudinale représentent des pistes prometteuses mais complexifient significativement l’architecture système. L’intégration de ces techniques nécessiterait des ressources computationnelles considérablement supérieures et soulèverait des questions de confidentialité et de performance.

Le problème du déséquilibre des classes, partiellement adressé par SVM-SMOTE, demeure un défi structurel en cybersécurité. La rareté intrinsèque de certaines attaques en environnement réel limite l’efficacité de toute technique d’apprentissage automatique, nécessitant des approches hybrides combinant détection automatisée et expertise humaine.

3.6 Perspectives d’amélioration et recherches futures

3.6.1 Améliorations architecturales

L’extension de notre architecture hiérarchique vers une approche multi-niveaux pourrait améliorer la granularité de détection. Une troisième étape spécialisée dans la détection R2L et U2R, intégrant des caractéristiques dérivées spécifiques (analyse temporelle, patterns comportementaux), pourrait compenser les limitations actuelles.

L’exploration d’architectures d’apprentissage profond plus sophistiquées (LSTM pour l’analyse temporelle, CNN pour l’extraction de motifs locaux, Transformers pour l’attention globale) offre des perspectives prometteuses. Ces architectures pourraient capturer des dépendances temporelles et spatiales que notre approche actuelle ne modélise pas explicitement.

L’intégration d’apprentissage par transfert depuis des domaines connexes (détection de fraude, analyse comportementale) pourrait enrichir les représentations apprises, particulièrement pour les classes minoritaires. Cette approche exploiterait les similarités structurelles entre différents domaines de détection d’anomalies.

3.6.2 Innovations méthodologiques

L’exploration de techniques d’apprentissage actif pourrait optimiser la collecte de nouveaux échantillons d’entraînement. En identifiant automatiquement les régions de l’espace des caractéristiques où le modèle est incertain, cette approche guiderait la collecte ciblée de données pour les classes problématiques.

L’intégration d’explicabilité (XAI - Explainable AI) améliorerait l’acceptabilité opérationnelle du système. Les techniques SHAP ou LIME pourraient identifier les caractéristiques déterminantes pour chaque prédiction, facilitant la validation par les experts sécurité et l’amélioration itérative des modèles.

L’apprentissage fédéré représente une opportunité d’amélioration collaborative sans partage de données sensibles. Cette approche permettrait l’entraînement de modèles sur des données distribuées, enrichissant la diversité des patterns appris tout en préservant la confidentialité organisationnelle.

3.6.3 Directions de recherche prometteuses

L'intégration de graphes de connaissances cybersécuritaires (MITRE ATT et CK) pourrait guider l'apprentissage vers des représentations alignées avec l'expertise humaine. Cette approche hybride combinerait apprentissage automatique et connaissances expertes structurées.

L'exploration d'approches adversariales pour l'entraînement de modèles robustes face aux attaques d'évasion constitue un axe de recherche crucial. Les attaquants développent de plus en plus des techniques pour contourner les systèmes de détection automatisés, nécessitant des défenses adaptatives.

La recherche sur l'apprentissage continu et l'adaptation de domaine pourrait adresser le défi de l'évolution temporelle des menaces. Ces techniques permettraient aux modèles de s'adapter automatiquement aux nouveaux patterns d'attaque sans oublier les connaissances antérieures.

3.7 Contributions et impact de la recherche

3.7.1 Contributions méthodologiques

Notre recherche apporte plusieurs contributions significatives au domaine de la détection d'intrusions par apprentissage automatique. L'architecture hiérarchique proposée démontre empiriquement les bénéfices de la spécialisation progressive pour les tâches de cybersécurité complexes.

L'évaluation comparative exhaustive de sept algorithmes d'apprentissage automatique fournit un référentiel empirique pour les chercheurs et praticiens. Ces résultats orientent le choix d'algorithmes selon les contraintes opérationnelles spécifiques (temps de calcul, interprétabilité, performance).

L'intégration réussie d'apprentissage supervisé et non-supervisé dans une architecture unifiée valide l'intérêt des approches hybrides pour la cybersécurité. Cette synergie optimise les avantages complémentaires de chaque paradigme d'apprentissage.

3.7.2 Impact pour la communauté scientifique

Nos résultats contribuent à l'établissement de bonnes pratiques pour l'évaluation de systèmes de détection d'intrusions. L'analyse détaillée des limitations et biais méthodologiques sensibilise la communauté aux défis d'évaluation dans ce domaine.

L'identification précise des classes d'attaques problématiques oriente les efforts de recherche futurs vers les défis les plus critiques. Cette caractérisation guide l'allocation des ressources de recherche vers les problèmes non résolus.

La validation de l'efficacité de SVM-SMOTE pour les données de cybersécurité encourage l'exploration de techniques d'équilibrage avancées dans ce domaine spécialisé. Cette contribution méthodologique bénéficie à l'ensemble de la communauté travaillant sur des données déséquilibrées.

Notre approche, par sa reproductibilité et sa documentation détaillée, facilite la comparaison et l'extension par d'autres recherches. Cette contribution à la reproductibilité scientifique renforce la validité collective des avancées dans le domaine.

Chapitre 4

CONCLUSION

Ce mémoire a présenté une approche innovante pour la détection d'intrusions réseau basée sur l'apprentissage automatique, appliquée au jeu de données NSL-KDD. À travers une méthodologie rigoureuse combinant classification hiérarchique, apprentissage supervisé et non-supervisé, ainsi que des techniques avancées de gestion du déséquilibre des classes, nous avons développé un système de détection performant et adapté aux défis contemporains de la cybersécurité.

4.1 Rappel du contexte et des objectifs

L'augmentation exponentielle des cyberattaques et la sophistication croissante des techniques d'intrusion constituent des défis majeurs pour la sécurité des infrastructures numériques contemporaines. Face à cette menace persistante, les systèmes de détection d'intrusions traditionnels, principalement basés sur des signatures, montrent leurs limites pour identifier les nouvelles formes d'attaques et s'adapter à l'évolution rapide du paysage des menaces.

Notre recherche s'est fixée comme objectif principal de développer un système de détection d'intrusions réseau exploitant les capacités de l'apprentissage automatique pour surmonter ces limitations. Spécifiquement, nous avons cherché à :

- Concevoir une architecture hiérarchique optimisant la détection binaire puis la classification fine des types d'attaques
- Évaluer comparativement l'efficacité de différents algorithmes d'apprentissage automatique pour la cybersécurité
- Intégrer des approches supervisées et non-supervisées dans un système unifié
- Développer des stratégies efficaces pour traiter le déséquilibre critique des classes d'attaques
- Valider la viabilité opérationnelle du système proposé sur des données réalistes

4.2 Synthèse des contributions principales

Notre travail apporte plusieurs contributions significatives au domaine de la détection d'intrusions par apprentissage automatique.

4.2.1 Architecture hiérarchique validée

L'approche hiérarchique en deux étapes constitue notre contribution méthodologique principale. Cette architecture démontre empiriquement les bénéfices de la spécialisation progressive : la première étape optimise la sensibilité globale aux intrusions, tandis que la seconde affine la caractérisation des menaces détectées. Cette décomposition facilite également la maintenance opérationnelle et l'évolution du système, chaque étape pouvant être optimisée indépendamment.

4.2.2 Efficacité démontrée de l'autoencodeur

L'intégration d'un autoencodeur pour la détection d'anomalies représente une innovation notable de notre approche. Avec un F1-score de 0,745 et une accuracy de 0,756, cet algorithme non-supervisé démontre des performances remarquables considérant son entraînement exclusivement sur des données normales. Cette capacité de détection sans connaissance préalable des patterns d'attaque offre une couverture prophylactique précieuse contre les menaces zero-day.

4.2.3 Validation comparative exhaustive

L'évaluation systématique de sept algorithmes d'apprentissage automatique fournit un référentiel empirique robuste pour la communauté scientifique. La supériorité du perceptron multi-couches (F1-score = 0,816, accuracy = 0,819) valide l'intérêt des approches neuronales pour capturer les relations non-linéaires complexes présentes dans les données de trafic réseau.

4.2.4 Impact quantifié de SVM-SMOTE

Notre étude démontre l'efficacité de la technique SVM-SMOTE pour améliorer la détection des classes minoritaires critiques. L'amélioration de 15,6% du F1-score macro confirme l'intérêt des techniques d'équilibrage sophistiquées, tout en révélant leurs limitations pour les classes ultra-minoritaires comme U2R.

4.3 Principaux résultats obtenus

Les expérimentations menées sur le dataset NSL-KDD révèlent des performances différenciées selon les types d'attaques, offrant une cartographie précise des capacités et limitations de notre approche.

4.3.1 Excellence en classification binaire

La classification binaire atteint des performances remarquables avec une accuracy de 81,9% et un F1-score de 0,816 pour le modèle MLP. Ces résultats positionnent notre système comme viable pour un déploiement opérationnel, particulièrement pour la détection préliminaire d'activités suspectes nécessitant une investigation approfondie.

4.3.2 Performances contrastées en classification multi-classes

La classification multi-classes révèle une hiérarchie claire de détectabilité :

- **Trafic Normal** : 95,5% de taux de réussite - Excellence dans l'identification du comportement légitime, minimisant les faux positifs
- **Attaques DoS** : 86,1% de taux de réussite - Détection efficace des menaces volumétriques grâce aux signatures statistiques distinctives
- **Attaques Probe** : 68,1% de taux de réussite - Performance acceptable pour les tentatives de reconnaissance
- **Attaques R2L** : 14,8% de taux de réussite - Défi majeur nécessitant des approches spécialisées
- **Attaques U2R** : 29,9% de taux de réussite - Performance critique révélant les limitations de l'approche réseau pure

4.3.3 Validation de l'approche d'équilibrage

L'application de SVM-SMOTE transforme la distribution des classes d'entraînement, passant de 125,973 à 336,715 échantillons. Cette intervention améliore significativement le F1-score macro (+15,6%) tout en maintenant une accuracy globale acceptable (78,9%), démontrant l'efficacité de cette technique pour les données de cybersécurité déséquilibrées.

4.4 Limitations reconnues et défis persistants

Notre recherche, malgré ses contributions significatives, présente plusieurs limitations qu'il convient de reconnaître pour orienter les développements futurs.

4.4.1 Contraintes liées au dataset

L'utilisation exclusive du dataset NSL-KDD, bien que standard dans la communauté, limite la généralisation temporelle de nos conclusions. Ce dataset, datant de plus d'une décennie, ne reflète pas nécessairement les techniques d'attaque contemporaines. L'absence de validation croisée sur des datasets plus récents (CICIDS-2017, UNSW-NB15) constitue une limitation méthodologique à adresser dans les travaux futurs.

4.4.2 Défis structurels des attaques sophistiquées

Les performances critiques pour les attaques R2L et U2R révèlent un défi structurel transcendant notre approche spécifique. Ces intrusions, conçues pour mimer le comportement normal, exploitent des vulnérabilités logiques plutôt que des anomalies de trafic, nécessitant des techniques de détection fondamentalement différentes intégrant l'analyse comportementale et l'inspection de contenu applicatif.

4.4.3 Limitations de l'augmentation synthétique

Bien que SVM-SMOTE améliore les performances globales, la génération d'échantillons synthétiques ne peut compenser entièrement l'absence de diversité dans les

exemples réels d'attaques ultra-minoritaires. Cette limitation souligne l'importance cruciale de la collecte de données réelles diversifiées pour les classes critiques.

4.5 Perspectives de recherche et recommandations

Les résultats obtenus ouvrent plusieurs axes de développement prometteurs pour améliorer les capacités de détection d'intrusions.

4.5.1 Améliorations architecturales immédiates

L'extension vers une architecture multi-niveaux intégrant une troisième étape spécialisée dans la détection R2L et U2R constitue une évolution naturelle de notre approche. Cette étape pourrait exploiter des caractéristiques dérivées spécifiques (analyse temporelle, patterns comportementaux longitudinaux) et des techniques d'apprentissage profond plus sophistiquées (LSTM, Transformers).

L'intégration d'explicabilité (XAI) améliorerait l'acceptabilité opérationnelle en permettant aux experts sécurité de comprendre et valider les décisions automatisées. Les techniques SHAP ou LIME pourraient identifier les caractéristiques déterminantes pour chaque prédiction, facilitant l'amélioration itérative des modèles.

4.5.2 Innovations méthodologiques futures

L'apprentissage actif représente une piste prometteuse pour optimiser la collecte de nouveaux échantillons d'entraînement. En identifiant automatiquement les régions d'incertitude du modèle, cette approche guiderait la collecte ciblée de données pour les classes problématiques.

L'apprentissage fédéré offre des perspectives d'amélioration collaborative sans compromission de la confidentialité. Cette approche permettrait l'entraînement sur des données distribuées, enrichissant la diversité des patterns appris tout en préservant la confidentialité organisationnelle.

L'intégration de graphes de connaissances cybersécuritaires (MITRE ATT et CK) pourrait guider l'apprentissage vers des représentations alignées avec l'expertise humaine, combinant apprentissage automatique et connaissances expertes structurées.

4.5.3 Recommandations pour le déploiement opérationnel

Nos résultats supportent un déploiement opérationnel immédiat pour la détection du trafic normal et des attaques DoS, avec surveillance renforcée pour les classes problématiques. Nous recommandons une approche hybride intégrant :

- Notre système automatisé pour la détection primaire et la classification des menaces volumétriques
- Des techniques d'analyse comportementale (UBA) pour compléter la détection R2L
- Une surveillance spécialisée des événements système (SIEM) pour les tentatives U2R
- Un processus de mise à jour continue des modèles basé sur les nouvelles menaces détectées

4.6 Impact et contribution à la cybersécurité

Cette recherche contribue significativement à l'avancement de la cybersécurité en démontrant la viabilité opérationnelle des approches d'apprentissage automatique hiérarchiques pour la détection d'intrusions réseau. Notre méthodologie, par sa reproductibilité et sa documentation exhaustive, facilite l'adoption et l'extension par la communauté scientifique et industrielle.

L'identification précise des classes d'attaques problématiques oriente les efforts de recherche futurs vers les défis les plus critiques, guidant l'allocation optimale des ressources de recherche et développement. La validation empirique de techniques comme SVM-SMOTE encourage l'exploration d'approches d'équilibrage avancées dans le domaine spécialisé de la cybersécurité.

Au-delà des contributions techniques, ce travail sensibilise la communauté aux défis méthodologiques de l'évaluation en cybersécurité, promouvant des pratiques d'évaluation plus rigoureuses et la validation multi-datasets pour renforcer la robustesse des conclusions scientifiques.

4.7 Conclusion finale

Ce mémoire démontre qu'une approche méthodique combinant apprentissage hiérarchique, techniques d'équilibrage avancées et intégration d'approches supervisées et non-supervisées peut produire un système de détection d'intrusions performant et déployable opérationnellement. Bien que des défis persistent, particulièrement pour les attaques sophistiquées, les résultats obtenus valident la pertinence de l'apprentissage automatique pour répondre aux enjeux contemporains de cybersécurité.

Les performances remarquables en classification binaire ($F1\text{-score} = 0,816$) et l'efficacité démontrée pour les menaces volumétriques positionnent notre système comme une solution viable pour renforcer significativement les capacités de détection des organisations. L'architecture proposée, par sa modularité et sa flexibilité, offre une base solide pour les développements futurs et l'intégration de techniques émergentes.

L'avenir de la détection d'intrusions résidera probablement dans l'hybridation intelligente d'approches automatisées et d'expertise humaine, exploitant les forces complémentaires de l'apprentissage automatique et de l'analyse experte pour construire des défenses adaptatives face à l'évolution constante des menaces cybernétiques.

Cette recherche, en contribuant à cette vision, participe à l'édification d'un cyberspace plus sûr et résilient pour nos sociétés numériques.

Bibliographie

- [1] Z. Tauscher, Y. Jiang, K. Zhang, J. Wang, H. Song, *Learning to Detect : A Data-driven Approach for Network Intrusion Detection*, arXiv preprint arXiv :2108.08394, 2021.
- [2] M. Tavallaee, E. Bagheri, W. Lu, A. A. Ghorbani, *A detailed analysis of the KDD CUP 99 data set*, IEEE Symposium on Computational Intelligence for Security and Defense Applications, pp. 1-6, 2009.
- [3] L. Dhanabal, S. Shantharajah, *A study on NSL-KDD dataset for intrusion detection system based on classification algorithms*, International Journal of Advanced Research in Computer and Communication Engineering, vol. 4, no. 6, pp. 446-452, 2015.
- [4] L. Breiman, *Random forests*, Machine Learning, vol. 45, no. 1, pp. 5-32, 2001.
- [5] C. Cortes, V. Vapnik, *Support-vector networks*, Machine Learning, vol. 20, no. 3, pp. 273-297, 1995.
- [6] Y. Freund, R. E. Schapire, *A decision-theoretic generalization of on-line learning and an application to boosting*, Journal of Computer and System Sciences, vol. 55, no. 1, pp. 119-139, 1997.
- [7] D. E. Rumelhart, G. E. Hinton, R. J. Williams, *Learning representations by back-propagating errors*, Nature, vol. 323, no. 6088, pp. 533-536, 1986.
- [8] G. E. Hinton, R. R. Salakhutdinov, *Reducing the dimensionality of data with neural networks*, Science, vol. 313, no. 5786, pp. 504-507, 2006.
- [9] N. V. Chawla, K. W. Bowyer, L. O. Hall, W. P. Kegelmeyer, *SMOTE : synthetic minority over-sampling technique*, Journal of Artificial Intelligence Research, vol. 16, pp. 321-357, 2002.
- [10] H. M. Nguyen, E. W. Cooper, K. Kamei, *Borderline over-sampling for imbalanced data classification*, International Journal of Knowledge Engineering and Soft Data Paradigms, vol. 3, no. 1, pp. 4-21, 2011.
- [11] S. García, J. Luengo, F. Herrera, *Data preprocessing in data mining*, Springer, vol. 72, 2015.
- [12] H. He, E. A. Garcia, *Learning from imbalanced data*, IEEE Transactions on Knowledge and Data Engineering, vol. 21, no. 9, pp. 1263-1284, 2009.
- [13] I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, 2016.
- [14] V. Chandola, A. Banerjee, V. Kumar, *Anomaly detection : A survey*, ACM Computing Surveys, vol. 41, no. 3, pp. 1-58, 2009.
- [15] D. E. Denning, *An intrusion-detection model*, IEEE Transactions on Software Engineering, no. 2, pp. 222-232, 1987.

- [16] S. García, M. Grill, J. Stiborek, A. Zunino, *An empirical comparison of botnet detection methods*, Computers & Security, vol. 45, pp. 100-123, 2014.
- [17] A. L. Buczak, E. Guven, *A survey of data mining and machine learning methods for cyber security intrusion detection*, IEEE Communications Surveys & Tutorials, vol. 18, no. 2, pp. 1153-1176, 2016.
- [18] G. P. Zhang, *Neural networks for classification : a survey*, IEEE Transactions on Systems, Man, and Cybernetics, Part C, vol. 30, no. 4, pp. 451-462, 2000.
- [19] B. Pfahringer, H. Bensusan, C. Giraud-Carrier, *Tell me who can learn you and I can tell you who you are : Landmarking various learning algorithms*, Proceedings of the 17th International Conference on Machine Learning, pp. 743-750, 2000.
- [20] J. R. Quinlan, *Induction of decision trees*, Machine Learning, vol. 1, no. 1, pp. 81-106, 1986.
- [21] V. Vapnik, *The nature of statistical learning theory*, Springer Science & Business Media, 1999.
- [22] T. Hastie, R. Tibshirani, J. Friedman, *The elements of statistical learning : data mining, inference, and prediction*, Springer Science & Business Media, 2009.
- [23] C. M. Bishop, *Pattern recognition and machine learning*, Springer, 2006.
- [24] K. P. Murphy, *Machine learning : a probabilistic perspective*, MIT Press, 2012.
- [25] G. James, D. Witten, T. Hastie, R. Tibshirani, *An introduction to statistical learning*, Springer, vol. 112, 2013.
- [26] KDD Cup 1999 Data, *The Third International Knowledge Discovery and Data Mining Tools Competition*, UCI KDD Archive, 1999.
- [27] S. J. Stolfo, W. Fan, W. Lee, A. Prodromidis, P. K. Chan, *Cost-based modeling for fraud and intrusion detection : Results from the JAM project*, Proceedings DARPA Information Survivability Conference and Exposition, vol. 2, pp. 130-144, 2000.
- [28] R. Lippmann, J. W. Haines, D. J. Fried, J. Korba, K. Das, *The 1999 DARPA off-line intrusion detection evaluation*, Computer Networks, vol. 34, no. 4, pp. 579-595, 2000.
- [29] M. V. Mahoney, P. K. Chan, *An analysis of the 1999 DARPA/Lincoln Laboratory evaluation data for network anomaly detection*, International Workshop on Recent Advances in Intrusion Detection, pp. 220-237, 2003.
- [30] J. McHugh, *Testing intrusion detection systems : a critique of the 1998 and 1999 DARPA intrusion detection system evaluations as performed by Lincoln Laboratory*, ACM Transactions on Information and System Security, vol. 3, no. 4, pp. 262-294, 2000.
- [31] S. Axelsson, *Intrusion detection systems : A survey and taxonomy*, Technical Report, Chalmers University of Technology, 2000.
- [32] T. F. Lunt, *A survey of intrusion detection techniques*, Computers & Security, vol. 12, no. 4, pp. 405-418, 1993.
- [33] H. Debar, M. Dacier, A. Wespi, *Towards a taxonomy of intrusion-detection systems*, Computer Networks, vol. 31, no. 8, pp. 805-822, 1999.
- [34] A. Patcha, J. M. Park, *An overview of anomaly detection techniques : Existing solutions and latest technological trends*, Computer Networks, vol. 51, no. 12, pp. 3448-3470, 2007.

- [35] C. F. Tsai, Y. F. Hsu, C. Y. Lin, W. Y. Lin, *Intrusion detection by machine learning : A review*, Expert Systems with Applications, vol. 36, no. 10, pp. 11994-12000, 2009.
- [36] A. A. Aburomman, M. B. I. Reaz, *A novel SVM-kNN-PSO ensemble method for intrusion detection system*, Applied Soft Computing, vol. 38, pp. 360-372, 2016.
- [37] K. Wang, S. J. Stolfo, *Anomalous payload-based network intrusion detection*, International Workshop on Recent Advances in Intrusion Detection, pp. 203-222, 2004.
- [38] T. Shon, J. Moon, *A hybrid machine learning approach to network anomaly detection*, Information Sciences, vol. 177, no. 18, pp. 3799-3821, 2007.
- [39] Y. Chen, A. Abraham, J. Yang, *Feature selection and intrusion detection using hybrid flexible neural tree*, International Symposium on Neural Networks, pp. 439-444, 2005.
- [40] M. Sabhnani, G. Serpen, *Application of machine learning algorithms to KDD intrusion detection dataset within misuse detection context*, International Conference on Machine Learning ; Models, Technologies and Applications, pp. 209-215, 2003.
- [41] N. B. Amor, S. Benferhat, Z. Elouedi, *Naive bayes vs decision trees in intrusion detection systems*, Proceedings of the 2004 ACM symposium on Applied computing, pp. 420-424, 2004.
- [42] S. Mukkamala, G. Janoski, A. Sung, *Intrusion detection using neural networks and support vector machines*, Proceedings of the 2002 International Joint Conference on Neural Networks, vol. 2, pp. 1702-1707, 2002.
- [43] J. Cannady, *Artificial neural networks for misuse detection*, National Information Systems Security Conference, pp. 368-381, 1998.
- [44] J. Ryan, M. J. Lin, R. Miikkulainen, *Intrusion detection with neural networks*, Advances in Neural Information Processing Systems, pp. 943-949, 1998.
- [45] S. Peddabachigari, A. Abraham, C. Grosan, J. Thomas, *Modeling intrusion detection system using hybrid intelligent systems*, Journal of Network and Computer Applications, vol. 30, no. 1, pp. 114-132, 2007.
- [46] S. Kumar, E. H. Spafford, *A pattern matching model for misuse intrusion detection*, Proceedings of the 17th National Computer Security Conference, pp. 11-21, 1994.
- [47] S. Forrest, S. A. Hofmeyr, A. Somayaji, T. A. Longstaff, *A sense of self for Unix processes*, Proceedings 1996 IEEE Symposium on Security and Privacy, pp. 120-128, 1996.
- [48] C. Warrender, S. Forrest, B. Pearlmutter, *Detecting intrusions using system calls : Alternative data models*, Proceedings of the 1999 IEEE Symposium on Security and Privacy, pp. 133-145, 1999.
- [49] W. Lee, S. J. Stolfo, *Data mining approaches for intrusion detection*, Proceedings of the 7th USENIX Security Symposium, pp. 79-94, 1998.
- [50] W. Lee, S. J. Stolfo, K. W. Mok, *A data mining framework for building intrusion detection models*, Proceedings of the 1999 IEEE Symposium on Security and Privacy, pp. 120-132, 1999.
- [51] P. Laskov, P. Düssel, C. Schäfer, K. Rieck, *Learning intrusion detection : supervised or unsupervised ?*, International Conference on Image Analysis and Processing, pp. 50-57, 2005.